

Python For Data Analytics

Proyecto Final – Análisis de Datos (Python)

Grupo 1

**Institución: Escuela Superior Politécnica del Litoral
(ESPOL)**

Estudiantes:

- ***Rodríguez Bustamante Emily Alejandra***
- ***Menoscal Chiriguaya Daniel Alejandro***
 - ***Macias Urgilés Angélica Maria***
 - ***Castro Valdiviezo Elsie Karina***

Año:

2025-2026

Análisis de Datos para la Detección de Fraude en Seguros de Auto

Resumen Ejecutivo

Este informe presenta un análisis profundo del dataset de seguros de automóviles con el objetivo de detectar patrones asociados al fraude en el proceso de reclamación. Se realizó un proceso de limpieza, selección y visualización de variables relevantes, permitiendo identificar segmentos de clientes y tipos de productos más propensos a presentar conductas fraudulentas. Los resultados destacan la concentración de fraudes en ciertas marcas y tipos de póliza, así como la mayor prevalencia en grupos de edad específicos y clientes con historial extenso de reclamos.

Gracias a estos hallazgos, el informe propone recomendaciones orientadas a mejorar la prevención y control del fraude, incluyendo auditorías focalizadas, estrategias de tarificación personalizadas y campañas de concientización para los perfiles más riesgosos. El análisis evidencia el valor estratégico del tratamiento e interpretación de datos en la gestión de riesgos de aseguradoras y en el diseño de acciones que contribuyan a la sostenibilidad y competitividad comercial.

Contexto y Problema

El fraude en seguros de autos representa un reto importante para las compañías aseguradoras, ya que impacta directamente en sus resultados y en la confianza hacia los asegurados. El objetivo de este análisis es descubrir patrones, relaciones y comportamientos dentro del dataset asignado para comprender qué factores permiten identificar posibles fraudes y optimizar la gestión de riesgos y reclamos en la empresa.

A continuación, se presentan los principales factores y comportamientos observados en el grupo de reclamos analizados, los cuales permiten comprender mejor cómo se manifiesta el fraude y qué variables influyen en su aparición.

Características del asegurado

Age (Edad del cliente): Información demográfica que influye en el perfil de riesgo.

DriverRating (Calificación del conductor): Un índice que resume el historial y comportamiento del asegurado.

Es una de las variables más relevantes, ya que comportamientos repetitivos suelen estar asociados con fraude.

Detalles de la póliza

Deductible (Deducible): Monto que el cliente paga de su bolsillo antes de recibir indemnización.

Un deducible bajo puede aumentar la frecuencia de reclamos.

Información temporal del reclamo

WeekOfMonth y WeekOfMonthClaimed: Semana del mes en que ocurrió y fue reportado el incidente.

Las aseguradoras detectan patrones donde ciertos reclamos fraudulentos se concentran al final del mes.

Variable objetivo

FraudFound_P: Indica si el reclamo fue clasificado como fraude (1) o no (0).

Solo 6% de los casos son fraude, lo cual genera un desbalance natural en este tipo de problemas.

Exploración Inicial del Dataset

Para iniciar el análisis, se realizó una exploración descriptiva de la estructura y contenido del dataset con el objetivo de comprender sus características generales y detectar posibles problemas de calidad de datos. El dataset contiene 15,000 registros y 27 variables, incluyendo atributos del asegurado, detalles del vehículo, tipo de póliza, historial de reclamos y la variable objetivo de fraude.

Se revisaron los tipos de datos, valores faltantes, duplicados y distribuciones iniciales. La mayoría de las variables presentan una estructura consistente y sin irregularidades, excepto

AccidentArea y MaritalStatus, que contenían valores nulos que fueron imputados como parte del proceso de limpieza.

Dimensiones y tipos de variables

- 15,000 registros
- 27 columnas
- Variables numéricas: Edad, precio del vehículo, calificación del conductor, deducible.
- Variables categóricas: Marca del vehículo, tipo de póliza, área del accidente, WeekOfMonthClaimed, estado civil, sexo.
- Variable objetivo: *FraudFound_P* (1 = fraude, 0 = no fraude)

Variable	Mín	Media	Máx	Por qué es importante
FraudFound_P	0	0.059	1	Proporcion de fraude (solo 6%). Es la variable objetivo.
Age	16	40.1	73	El riesgo cambia por edad; hay outliers(16).
DriverRating	1	2.49	4	Conductores con peor rating pueden
Deductible	300	407	700	Deducibles bajos pueden asociarse
WeekOfMonthClaimed	1	2.69	5	Util para ver si el fraude ocurre a fin de mes

Valores nulos y duplicados

- AccidentArea: nulos imputados con la moda
- MaritalStatus: nulos imputados con la moda
- No se detectaron registros duplicados relevantes

Estadísticas descriptivas clave


- Edad promedio: ~38 años
- Precio del vehículo: mayor concentración entre 20,000 y 30,000
- Deducibles más comunes: 300–400
- Solo el 6% de los casos fueron clasificados como fraude

Reflexión sobre la calidad de datos

En general, el dataset presenta buena consistencia y permite un análisis confiable. Los valores faltantes fueron mínimos y no afectaron la integridad del estudio. Las distribuciones iniciales revelaron patrones importantes, como la concentración de clientes en zonas urbanas y la predominancia de vehículos sedan, lo que facilitó la definición de variables clave para el análisis profundo posterior.

Principales Hallazgos y Visualizaciones

1. Distribución de Edad del Asegurado




Interpretación:

El histograma muestra que la mayor parte de asegurados se concentra entre los 30 y 50 años.

Esta distribución es importante porque refleja el rango de edad predominante en la base de clientes y sirve como referencia para evaluar posteriormente si existen diferencias significativas entre asegurados que cometen fraude y los que no.


2. Distribución General de Marcas de Vehículo



Interpretación:


Pontiac, Toyota, Honda y Mazda son las marcas más comunes dentro del dataset. Esta distribución permite identificar qué marcas tienen mayor presencia y, por lo tanto, mayor volumen de reclamos. Aunque no implica fraude por sí sola, sirve de contexto para análisis más focalizados.

3. Tipo de Vehículo y Presencia de Fraude

**Interpretación:**

Los autos tipo **sedan** no solo son los más frecuentes, sino también los que presentan la mayor cantidad absoluta de fraudes. En contraste, los vehículos **utility** muestran casi nula incidencia, lo que indica que ciertos segmentos vehiculares representan menor riesgo para la aseguradora.


4. Área del Accidente



Interpretación:

La gran mayoría de reclamos provienen de zonas urbanas. Esto es coherente con la mayor circulación y densidad poblacional en estas áreas, donde ocurren más siniestros y potencialmente se reportan más reclamos, incluyendo fraudulentos.


5. 10 Marcas con Mayor Probabilidad de Fraude



Interpretación:


Mercedes destaca con una probabilidad de fraude cercana al 25%, seguida por Acura con alrededor del 13%. Esto revela que ciertos fabricantes, aunque no sean los más comunes, presentan un comportamiento más riesgoso y requieren mayor control y revisión de documentos al procesar reclamos.

6. Precio del Vehículo o Fraude

**Interpretación:**

Los rangos de precios entre reclamos fraudulentos y no fraudulentos son muy similares. Esto indica que el valor del vehículo no es un factor determinante en la aparición de fraude, y que los incidentes se distribuyen de forma pareja entre autos de distintos precios.


7. Proporción de Fraude por Tipo de Póliza



Interpretación:

Los rangos de precios entre reclamos fraudulentos y no fraudulentos son muy similares. Esto indica que el valor del vehículo no es un factor determinante en la aparición de fraude, y que los incidentes se distribuyen de forma pareja entre autos de distintos precios.


8. Fraude Promedio por Tipo de Póliza



Interpretación:


La tendencia se confirma: las pólizas deportivas mantienen el mayor riesgo de fraude, mientras que las pólizas **Utility – All Perils** prácticamente no registran casos. Esto sugiere diferencias estructurales en los perfiles de los asegurados según el tipo de cobertura contratada.

9. Fraude por Número de Reclamos Pasados

**Interpretación:**

Sorprendentemente, los asegurados sin reclamos previos presentan la mayor tasa de fraude (~8%). Esto puede deberse a fraudes de oportunidad, donde un cliente que nunca ha reclamado antes intenta obtener un beneficio indebido.


10. Historial de Reclamos (Frecuencia)



Interpretación:

La mayoría de asegurados tiene entre 2 y 4 reclamos anteriores, aunque existe un número considerable sin ningún reclamo. Esto ayuda a identificar patrones de recurrencia y posibles comportamientos repetitivos.


11. Edad vs Fraude



Interpretación:


Ambos grupos —fraude y no fraude— presentan distribuciones muy similares. No existe una diferencia notable por edad, lo cual indica que este atributo no influye significativamente en la probabilidad de cometer fraude.

12. Porcentaje de Fraude por Estado Civil

**Interpretación:**

El grupo con mayor incidencia de fraude es el de personas viudas (~9%). Esto podría indicar un perfil con necesidades económicas particulares o situaciones personales que motivan reclamos dudosos.


13. Fraude por Sexo



Interpretación:


Los hombres registran una tasa ligeramente mayor de fraude (6%) en comparación con las mujeres (4%). Aunque la diferencia no es extrema, aporta información útil para segmentar estrategias de evaluación y prevención.

14. riesgo de accidentes por tipo de póliza



Interpretación:

Las pólizas asociadas a vehículos tipo Sedan concentran una mayor proporción de asegurados de alto riesgo. Esto se debe principalmente a dos factores: en primer lugar, los sedanes son el tipo de vehículo más común en la muestra, lo que incrementa naturalmente el volumen de reclamos provenientes de este segmento. En segundo lugar, sus costos de adquisición y mantenimiento suelen ser más bajos, lo que atrae a perfiles de conductores con mayor propensión a incidentes o comportamientos de riesgo.

15. Distribución del valor del deducible**Interpretación:**

El análisis muestra que la mayor parte de los casos de fraude se concentra en deducibles bajos, alrededor de 400. Este comportamiento puede explicarse por dos factores principales. Primero, ese rango de deducible es el más común dentro del portafolio de pólizas, por lo que acumula un mayor número de reclamos, incluyendo los fraudulentos. Segundo, los deducibles bajos reducen la barrera de costo para el asegurado, haciendo que el monto a pagar de su bolsillo sea relativamente pequeño. Esto puede incentivar intentos de fraude, ya que el costo inicial para “activar” la reclamación es percibido como asumible frente al posible beneficio obtenido. La combinación de alta frecuencia y bajo costo de entrada contribuye a que este segmento presente

una mayor incidencia de fraude.

Con el análisis realizado, ahora podemos abordar las preguntas clave del estudio. Los hallazgos obtenidos nos permiten identificar patrones claros de fraude, los perfiles más riesgosos y las relaciones entre las variables evaluadas.

¿Qué patrones permiten identificar fraude en los reclamos?

Ciertas marcas presentan tasas significativamente más altas de fraude

Marcas como Mercedes (~25%) y Acura (~13%) destacan con las probabilidades más altas.

El fraude se concentra en ciertos tipos de póliza

Las pólizas deportivas (“Sport”) muestran la mayor incidencia de fraude, mientras que las Utility – All Perils prácticamente no registran casos.

El comportamiento temporal influye: semanas del mes

Las aseguradoras detectan que los reclamos fraudulentos suelen concentrarse al final del mes, lo que coincide con patrones conocidos en fraude.

Mayor fraude en clientes sin reclamos pasados

El grupo con 0 reclamos previos presenta una tasa de fraude sorprendentemente alta (~8%), lo que sugiere fraudes de oportunidad.

Estado civil y sexo muestran diferencias

Personas viudas: mayor incidencia (~9%).

Los hombres tienen ligeramente más fraude (6% vs 4%).

Mayor fraude en vehículos tipo sedan.

Los sedan no solo son los más frecuentes, sino también los que acumulan la mayor cantidad absoluta de fraudes.

¿Qué variables definen a los clientes con mayor probabilidad de fraude?
Según el informe, las variables más determinantes para identificar clientes con mayor riesgo de fraude son:

- Marca del vehículo (Make)
- Tipo de póliza (PolicyType)
- Número de reclamos pasados
- Estado civil (MaritalStatus)
- Sexo (Sex)
- Categoría del vehículo (VehicleCategory)

Variables que NO influyen significativamente según el informe:

- Edad (Age)
- Precio del vehículo (VehiclePrice)

¿Existen relaciones entre características del vehículo, asegurado y la ocurrencia de fraude?

El análisis muestra que sí existen relaciones entre las características del vehículo, del asegurado y la ocurrencia de fraude. Marcas como Mercedes y Acura, los vehículos tipo sedan y las pólizas deportivas presentan mayor probabilidad de fraude. Además, ciertos perfiles del asegurado,

como las personas viudas, los hombres y quienes no tienen reclamos previos, también muestran una mayor incidencia. En cambio, variables como la edad o el precio del vehículo no presentan una relación significativa con el fraude.

Conclusión Principal

El análisis evidencia que el fraude en seguros de autos no ocurre al azar, sino que responde a perfiles definidos por variables como la marca y tipo de vehículo, la edad y el historial del asegurado. Estos hallazgos son cruciales para crear modelos más efectivos de prevención y detección, así como para la segmentación de clientes y la optimización de productos.

Recomendaciones de negocio basadas en el análisis

- Fortalecer auditorías y controles en los segmentos identificados como de mayor riesgo: marcas con alta incidencia, pólizas deportivas, vehículos sedan y asegurados sin historial previo de reclamos.
- Optimizar la estructura de precios y suscripción, incorporando la probabilidad de fraude según el perfil del asegurado y las características del vehículo.
- Mejorar la calidad y completitud de la información registrada en los reclamos, especialmente en variables clave como tipo de póliza, deducible, historial y zona del accidente.
- Implementar campañas de prevención y concientización dirigidas a los grupos con mayor incidencia, reforzando la información sobre consecuencias legales y contractuales del fraude.
- Priorizar revisiones manuales o automatizadas en reclamos presentados al final del mes, por su relación con comportamientos sospechosos.

Acciones propuestas para detección y mitigación del fraude

- Desarrollar modelos predictivos utilizando las variables determinantes (marca, tipo de póliza, historial de reclamos, deducible, estado civil, sexo).
- Establecer alertas tempranas para detectar patrones de riesgo, como reclamos con deducibles bajos o asegurados sin reclamos previos.
- Aplicar sistemas de validación reforzada para marcas y pólizas con histórico elevado de fraude.
- Integrar reglas de negocio que automaticen el direccionamiento de reclamos sospechosos hacia áreas de revisión especializada.
- Monitorear comportamiento temporal, especialmente reclamos realizados a fin de mes, junto con la coherencia entre la semana del accidente y la semana del reclamo.

Oportunidades para futuras investigaciones o mejoras

- Profundizar en modelos avanzados de machine learning, comparando su precisión con métodos tradicionales de detección de fraude.
- Incorporar nuevas variables externas, como datos socioeconómicos o históricos de aseguradoras anteriores, para refinar la estimación de riesgo.
- Evaluar el impacto económico del fraude para priorizar intervenciones y justificar inversiones en sistemas antifraude.
- Analizar longitudinalmente cómo cambian los patrones de fraude a lo largo del tiempo y si ciertas políticas de control reducen su incidencia.
- Implementar técnicas de segmentación y clustering para descubrir subgrupos no evidentes que puedan estar asociados con fraude emergente.

Anexos

Diccionario de variables

A continuación, se presenta un resumen de las variables incluidas en el dataset:

- **Age:** Edad del cliente
- **Sex:** Sexo del asegurado
- **MaritalStatus:** Estado civil
- **Make:** Marca del vehículo
- **VehicleCategory:** Categoría del vehículo
- **VehiclePrice:** Rango de precio del vehículo
- **AccidentArea:** Zona donde ocurrió el accidente
- **PastNumberOfClaims:** Historial de reclamos previos
- **PolicyType:** Tipo de póliza
- **Deductible:** Valor del deducible
- **FraudFound_P:** Variable objetivo (1 = fraude, 0 = no fraude)

Anexo 2. Notas técnicas

- Imputación de nulos realizada en AccidentArea y MaritalStatus (método: moda).
- No se eliminaron registros.
- Se verificaron categorías inconsistentes.
- Análisis hecho con Python (pandas, seaborn y matplotlib).