



PERFILES DE RIESGO DE ACCIDENTES Y FACTORES ASOCIADOS AL FRAUDE EN SEGUROS DE AUTOS




CONTENIDO

- 01 Introducción
- 02 Modelo de negocio
- 03 Limpieza e Imputación
- 04 Comparativa Imputación
- 05 Exploración de los Datos
- 06 Gráficas de riesgo
- 07 Conclusiones
- 08 Muchas gracias




Importante evaluar

**Calidad y
Consistencia
de los Datos**



La presencia de valores nulos en variables clave como AccidentArea o MaritalStatus, así como la detección de outliers en Age, puede distorsionar el análisis y los resultados. Estos problemas pueden generar sesgos o conclusiones erróneas si no son tratados

**Desbalance
en los Datos**




La mayoría de reclamos son legítimos mientras los fraudes conforman una minoría. Esto dificulta la identificación de patrones, ya que los algoritmos tienden a ajustarse a la clase mayoritaria y pueden fallar en identificar fraude.

IDENTIFICACIÓN DE VARIABLES

Se seleccionaron las variables con valor analítico para el estudio:
age,sex,brand,PolicyType,
MaritalStatus,PastNumberOfClaims,
FraudFound_P.

Estas permiten analizar patrones en reclamos y posibles indicios de fraude.



LIMPIEZA E IMPUTACIÓN DE DATOS



Etapa del proyecto donde se revisó la calidad del dataset y se trataron los valores faltantes.

Este proceso asegura que los datos sean completos, consistentes y listos para el análisis.



REVISIÓN DEL DATASET



REVISIÓN INICIAL DEL DATASET

Se identificaron las columnas, tipos de datos y registros totales.

El dataset contiene información sobre pólizas, reclamos y variables demográficas de los asegurados

```
Archivo cargado correctamente.  
Número de filas y columnas: (15420, 34)
```

```
Vista preliminar de los datos:
```

```
      Unnamed:  Month  WeekOfMonth  DayOfWeek  Make  AccidentArea  DayOfWeekClaimed  MonthClaimed  We  
0      0      Dec           5  Wednesday  Honda      Urban      Tuesday      Jan  
1      1      Jan           3  Wednesday  Honda      Urban      Monday      Jan  
2      2      Oct           5    Friday  Honda      Urban      Thursday     Nov  
3      3      Jun           2   Saturday  Toyota     Rural      Friday      Jul  
4      4      Jan           5    Monday  Honda      Urban      Tuesday     Feb
```

```
5 rows × 34 columns
```


DETECCIÓN DE VALORES NULOS


Cantidad de valores nulos por columna:

Unnamed: 0	0
Month	0
WeekOfMonth	0
DayOfWeek	0
Make	0
AccidentArea	323
DayOfWeekClaimed	0
MonthClaimed	0
WeekOfMonthClaimed	0
Sex	0
MaritalStatus	215
Age	0
Fault	0
PolicyType	0
VehicleCategory	0
VehiclePrice	0
FraudFound_P	0
PolicyNumber	0
RepNumber	0
Deductible	0
DriverRating	0
Days_Policy_Accident	0
Days_Policy_Claim	0
PastNumberOfClaims	0
AgeOfVehicle	0
AgeOfPolicyHolder	0

- En esta gráfica se puede ver la cantidad de valores nulos por columna.
- Solo AccidentArea y MaritalStatus presentan datos faltantes, mientras que el resto del dataset está completo.
- Esto nos permitió identificar qué variables requerían imputación antes del análisis.

AgeOfVehicle	0
AgeOfPolicyHolder	0
PoliceReportFiled	0
WitnessPresent	0
AgentType	0
NumberOfSupplements	0
AddressChange_Claim	0
NumberOfCars	0
Year	0
BasePolicy	0
dtype: int64	



PROCESO DE IMPUTACIÓN DE DATOS



- Los nulos fueron reemplazados con la moda: AccidentArea → Urban y MaritalStatus → Married.
- Esto evitó eliminar registros y conservó la distribución del dataset.




VARIABLES AFECTADAS

- Se reemplazaron los valores faltantes en AccidentArea y MaritalStatus utilizando la moda.
- Este método conserva la coherencia del dataset sin eliminar registros.
- Asegura que todas las variables categóricas queden completas.




CUADRO COMPARATIVO DE FRECUENCIAS ANTES Y DESPUÉS DE IMPUTAR

Las gráficas evidencian que las categorías predominantes se mantuvieron estables y que los cambios fueron mínimos, asegurando que la información permanezca coherente y lista para el análisis posterior.



EXPLORACIÓN DE DATOS

Etapa del proyecto donde se identificaron las variables relevantes del dataset SafeClaim y se obtuvieron estadísticas descriptivas para conocer el comportamiento general de los datos.





ESTADÍSTICA DESCRIPTIVA DE VARIABLES

Variable	Mín	Media	Máx	Por qué es importante
FraudFound_P	0	0.059	1	Proporcion de fraude (solo 6%). Es la variable objetivo.
Age	16	40.1	73	El riesgo cambia por edad; hay outliers(16).
DriverRating	1	2.49	4	Conductores con peor rating pueden
Deductible	300	407	700	Deducibles bajos pueden asociarse
WeekOfMonthClaimed	1	2.69	5	Util para ver si el fraude ocurre a fin de mes


AREA DEL ACCIDENTE

La mayoría de accidentes provienen de zonas urbanas debido a mayor densidad de tráfico y exposición al riesgo; las áreas rurales representan una proporción mínima.






podemos ver como las edades de los asegurados donde hay una mayor densidad entre 30 y 50 años



existe mucha más presencia de hombres que de mujeres, útil para detectar que género frecuenta más el fraude



se nota una mayor presencia de solteros, es útil para ver si ciertos estados civiles frecuentan cometer fraudes

PREGUNTA 1

¿Cómo se segmentan los clientes según su riesgo de accidentes?


DISTRIBUCIÓN DE SEGMENTOS

El riesgo se define con 3 criterios:

- Más de 2 reclamos previos
- Edad menor a 25 años
- Calificación de conductor menor o igual 2.

Si cumple uno, es alto riesgo; si no, bajo riesgo.

Esto permite comparar asegurados de forma más justa y detectar patrones.




PREGUNTA 2

¿Existe relación entre el tipo de póliza y el riesgo de accidentes?

RIESGO POR TIPO DE PÓLIZA

Las pólizas Sedan concentran más asegurados de alto riesgo porque:

- Son las más comunes
- Elegidas por conductores jóvenes,
- Costos más bajos atraen perfiles con mayor propensión a accidentes.




PREGUNTA 3

¿Cómo varía la frecuencia de fraude en los reclamos según el valor del deducible seleccionado?

FRAUDE SEGÚN DEDUCIBLE

La mayor cantidad de fraudes ocurre en el deducible de 400 por ser el valor más común, no necesariamente porque ese valor favorezca el fraude.


No se observa un patrón claro de aumento o disminución del fraude según cambia el deducible.



PREGUNTA 4

¿Qué variables definen a los clientes con mayor probabilidad de fraude?

Podemos ver que el tipo de auto más común (sedán) es el más propenso a cometer fraude, concentran más asegurados de alto riesgo como son los jóvenes.



CONCLUSIONES

- El alto riesgo se concentra en jóvenes con varios reclamos previos.
- Los Sedán presentan más alto riesgo y más casos de fraude.
- No hay relación clara entre deducible y fraude.
- La mayoría de accidentes ocurren en zonas urbanas.

RECOMENDACIONES

- Enfocar controles en perfiles jóvenes y autos Sedán.
- Ajustar primas y políticas según nivel de riesgo.
- Revisar deducibles más usados para auditoría.
- Fortalecer prevención en zonas urbanas.

MUCHAS GRACIAS

INTEGRANTES

- Elsie Castro
- Angélica Macías
- Daniel Menoscal
- Emily Rola

